

Python Libraries - Moed A Exam

Question 1

הכנת מידע

לפניך קבצי המידע הבאים:

Customers.csv, Items.csv, order_item.csv, orders.csv

חקור את המידע

- הדפס לכל טבלה (בפעולה אחת פר טבלה) את פרטי שמות העמודות, הטיפוס, וכמות העמודות שאינן Null (ועוד)
- הדפס לכל טבלה (בפעולה אחת פר טבלה) את שמות העמודות, הערכים הממוצעים, ערך MIN, ערך MAX חציון (ועוד)
- הדפס לכל טבלה את 5 הערכים הראשונים

מחיקת כפילויות

בטבלת items קיימים מוצרים שמופיעים מספר פעמים (מוצר עם אותו השם) והוחלט לשמור במוצרים בעלי אותו שם, את המוצר עם הכי הרבה פרטים not-null, ואת היתר למחוק.
רמז: (עקוב אחרי הדוגמא שעשינו בשיעור ויישם אותה כאן),
דרך פעולה-

- הוסף עמודה חדשה הסופרת כמה ערכי not-null יש בכל שורה
- מיין לפי שם המוצר + העמודה החדשה שייצרת, מהגדול לקטן
- הסר את הכפילויות לפי שם המוצר (שמור רק את המופע הראשון)

עדכון טבלת order_item:

- החלף את ה-id של המוצרים עם הכפילויות ל-id של המוצר עם הכי הרבה פרטים not-null. לדוגמא:

		Photography				
48	Camera	Equipment	2039.08	471	Panasonic	TRUE
28	Camera		695.71		Sony	FALSE

כאן, מכיוון שתוסר המצלמה עם id 28 יש לשנות בטבלת order_item את כל המכירות של מוצר המצלמה עם id 28 ל- 48

מחק מטבלת customers את כל הלקוחות אשר חסר להם 3 או יותר שדות
מחק מטבלת order_item את כל המכירות של הלקוחות שהסרת
בסעיף הקודם

Question 2

ניתוח מידע

השתמש בקבצי המידע הבאים:

Customers.csv, Items.csv, order_item.csv, orders.csv

1. מה מחיר ממוצע של פריט
2. מי הלקוח שרכש הכי הרבה מוצרים
3. הוסף עמודה total_price לטבלת order_item, המחשבת את עלות הקנייה הכוללת (מחיר מוצר * כמות)
4. הצג כל קנייה ואת המחיר הכולל שלה
5. מצא מה היא הקנייה הכי יקרה שבוצעה? הכי זולה? ממוצע?
6. מטבלת customers, צור טבלת PIVOT ובה הצג כל לאום כאינדקס, ואת ה-gender כעמודות. הצג כמה לקוחות משתייכים לאותו המגדר באותו הלאום. לדוגמא (פלט חלקי של הטבלה...)-

	gender	Agender	Bigender	Female	Genderfluid	Genderqueer
nationallity						
Argentina	1	0	10	1	0	0
Brazil	0	0	6	0	0	0

חקור והצג בגרף את הפרטים הבאים:

המלצה: הסר שורות עם ערכים ריקים

- (1) פילוג לקוחות לפי מגדר, gender
- (2) פילוג כמות לקוחות לפי לאום
- (3) הסטוגרמת פילוג לקוחות לפי גיל
- (4) גרף המציג כמות לקוחות חדשים שהצטרפו, לפי שנים
- (5) גרף המציג כמות מכירות לפי חודשים
- (6) הסטוגרמת פילוג כמות קניות לפי גיל (יש להחשיב כל קניה בספירה אחת. אין צורך לספור כמות מוצרים וכו') – האם יש מגמה ליותר/פחות קניה בטווחי גיל מסויימים?
- (7) *אתגר: עלות קניות לפי לאום. כלומר- נסכום את סך עלות הקניות שנעשו לכל המוצרים עבור כל לקוח, נחבר ביחד את כל קניית הלקוחות מאותו לאום – ואז נראה כמה עלות יש פר לאום

Question 3

? שאלות:

1. `df.dropna`

- א. מוחקת כפילויות מתוך עמודות
- ב. מוחקת שורות שמכילות ערכים חסרים (NaN)
- ג. מחליפה ערכים חסרים בערך ברירת מחדל
- ד. מוחקת את עמודת האינדקס מהטבלה

2. `df['city'].nunique`

- א. מחזיר את שם העיר שהופיעה הכי הרבה פעמים
- ב. מחזיר רשימה של כל הערים בטבלה
- ג. מחזיר את מספר הערכים השונים בעמודה 'city'
- ד. מוחק ערכים כפולים מהעמודה 'city'

3. `df['gender'].replace({'M': 'Male', 'F': 'Female'})`

- א. ממיר את הערכים למספרים לפי סדר הופעה
- ב. מחליף את ערכי העמודה gender לפי מפת המרה
- ג. מסנן את הרשומות שבהן gender הוא M או F
- ד. מחבר בין ערכים שונים בעמודה gender

4. `df.sample(5)`

- א. בוחר את 5 הערכים הקטנים ביותר בטבלה
- ב. מחזיר את כל הערכים של עמודת sample
- ג. בוחר 5 שורות אקראיות מהטבלה
- ד. יוצר עותק של הטבלה עם 5 עמודות בלבד

5. `df['score'].fillna(0)`

- א. מוחק את כל הערכים בעמודה score
- ב. מסמן את השורות בהן הערך הוא אפס
- ג. ממלא את הערכים החסרים בעמודה score עם אפס
- ד. ממיר את כל הערכים באפסים

`df.drop_duplicates` .6

- א. מוחקת שורות שמכילות ערכים חסרים
 - ב. מחליפה ערכים כפולים בערך ממוצע
 - ג. מוחקת שורות כפולות בטבלה
 - ד. מוחקת את כל הערכים הייחודיים בטבלה
-

`df['price'].nlargest(3)` .7

- א. מחזיר את 3 הערכים הקטנים ביותר בעמודת price
 - ב. מחזיר את 3 הערכים החסרים בעמודת price
 - ג. מחזיר את 3 הערכים הנפוצים ביותר בעמודת price
 - ד. מחזיר את 3 הערכים הגדולים ביותר בעמודת price
-

`df['city'].value_counts` .8

- א. מציג את הערכים המופיעים בעמודה בסדר אקראי
 - ב. מחזיר את מספר ההופעות של כל ערך בעמודה
 - ג. מוחק כפילויות בעמודת city
 - ד. ממיר ערכים טקסטואליים למספרים
-

`df['quantity'] > 100` .9

- א. בודק אילו שורות בעמודה quantity שוות בדיוק ל-100
 - ב. מסנן רק את השורות שהכמות בהן שווה לאפס
 - ג. יוצר סדרה בוליאנית של True/False לפי תנאי
 - ד. משנה את הערכים בעמודה ל-True
-

`(df.groupby('category')).mean` .10

- א. מחלק את הטבלה לפי קטגוריה ומחשב ממוצע לעמודות מספריות
- ב. מוחק ערכים כפולים בעמודת קטגוריה
- ג. מחזיר רק את הקטגוריה שהופיעה הכי הרבה
- ד. משכפל את הקטגוריות לפי מספר ההופעות שלהן